Домашнее задание 4

Клиническая аннотация генетических вариантов

Чепеньков Артём Игоревич | ФИТ НГУ, 23213 | Набор student_29

Homo sapiens | GRCh38

Исходные данные и статистика

Исследован student_29.vcf: 50 уникальных биаллельных SNV, 8 на хромосоме 21 и 42 на хромосоме 22. Транзиции (A↔G, C↔T): 44; трансверсии: 6; Ti/Tv = 7,33. Это описательная характеристика учебной выборки, а не оценка качества полного экзома или генома.

VCF содержит восемь столбцов: CHROM - хромосома, POS - позиция с нумерацией от 1, ID - исходный rsID, REF/ALT - референсный и альтернативный аллели, QUAL - качество вызова, FILTER - статус фильтров, INFO - дополнительные аннотации. QUAL, FILTER и INFO имеют значение «.» (нет данных); FORMAT, генотипы и сведения об образце отсутствуют.

Методика и выбор транскрипта

Аннотации получены через публичные API: Ensembl VEP release 116, NCBI ClinVar E-utilities и gnomAD GraphQL (dataset gnomad_r4, GRCh38). Настройки сохранены в annotation_settings.json. API gnomAD не возвращает в использованном запросе номер минорной версии, поэтому он не приписывается результатам.

В сводку взято most_severe_consequence, рассчитанное VEP по всем транскриптам. Среди транскриптов с этим последствием приоритет: MANE Select → canonical → protein_coding → лексикографически первый transcript_id. Таким образом, MANE Select выбирается только при равной тяжести. Это собственное правило свёртки, не параметр VEP --pick. Все 1431 транскриптные аннотации и альтернативные последствия сохранены отдельно.

ClinVar проверен двумя поисками: по rsID и по координатам chrpos38. Кандидаты объединены, затем строго сопоставлены GRCh38 + CHROM + POS + REF + ALT. Сохранены агрегированная germline-классификация, review status и отдельные утверждения. gnomAD AF относится к ALT и вычисляется как AC/AN; частоты экзомов и геномов приведены раздельно, без сложения когорт. NA означает недоступное значение; not_found - отсутствие точного совпадения после успешного поиска.

Общий результат

VEP и gnomAD дали результаты для всех 50 вариантов. ClinVar: 11 точных совпадений и 39 вариантов без записи для данного аллеля. Есть одна конфликтующая классификация. Сводная таблица содержит ровно одну строку на исходный вариант; исходный порядок сохранён.

Число вариантов по наиболее значимому последствию VEP: missense_variant: 30; synonymous_variant: 19; splice_polypyrimidine_tract_variant: 1.

Разбор трёх вариантов

1. rs115686643 | LARGE1 | 22:33316147 G>A

VEP: synonymous_variant, ENST00000397394.8:c.1389C>T; ENSP00000380549.2:p.Tyr463=. В выбранном транскрипте замена синонимическая: аминокислота сохраняется. AF ALT: экзомы 3.55719e-05; геномы 3.94374e-05. В ClinVar VCV000902052: Conflicting classifications of pathogenicity, review status: criteria provided, conflicting classifications. Конфликт состоит из Uncertain significance (две SCV-записи одного отправителя) и Likely benign (другой отправитель); это не конфликт «патогенный/доброкачественный». Само синонимическое последствие не исключает влияние на сплайсинг, но в полученных данных нет основания считать вариант доказанно патогенным.

2. rs2073748 | ARVCF | 22:19981448 G>A

VEP: missense_variant, ENST00000263207.8:c.659C>T; ENSP00000263207.3:p.Pro220Leu, MANE Select NM_001670.3; предсказана замена пролина на лейцин. AF ALT: экзомы 0.358148; геномы 0.358925. ClinVar VCV001288334: Benign; review status: criteria provided, multiple submitters, no conflicts. На выбранном транскрипте SIFT = 0,02 (deleterious_low_confidence), PolyPhen = 0 (benign). Различие предсказателей показывает, что молекулярное последствие и вычислительный прогноз сами по себе не равны клинической патогенности. Высокая популяционная частота согласуется с доброкачественной интерпретацией ClinVar.

3. rs3989369 | MRPL39 | 21:25606638 A>G

VEP: missense_variant, ENST00000352957.9:c.91T>C; ENSP00000284967.7:p.Ser31Pro, MANE Select NM_017446.4; предсказана замена серина на пролин. AF ALT: экзомы 0.950435; геномы 0.909263. В ClinVar точная запись для A>G не найдена. В этой позиции есть VCV000769210 с A>A (референсный аллель, p.Ser31=), классифицированная Benign; её интерпретация не переносилась на A>G. ALT встречается чаще REF, поэтому AF здесь не следует называть частотой минорного аллеля. Столь высокая частота не поддерживает гипотезу о редком высокопенетрантном патогенном аллеле, однако отсутствие записи ClinVar не является самостоятельной клинической классификацией.

Заключение и ограничения

Наиболее интересны LARGE1 с конфликтом VUS/Likely benign, ARVCF с missense-последствием при согласованной доброкачественной клинической оценке и MRPL39, где сопоставление только по позиции привело бы к неверной аннотации. Эти примеры показывают разницу между предсказанным молекулярным изменением, частотой аллеля и клинической классификацией.

Выборка мала, учебная, ограничена двумя хромосомами и известными rsID; она не представляет весь геном. Без генотипов, зиготности, фенотипа, происхождения, семейного анамнеза и качества вызовов невозможно определить причину заболевания или оценить индивидуальный риск. Частоты зависят от состава популяций и покрытия; агрегированные AF не заменяют популяционный анализ. Выбор самого тяжёлого последствия может выделять редкую изоформу, а аннотации и классификации меняются между версиями баз. Конфликтующие и отсутствующие интерпретации сохранены явно; собственная ACMG-классификация не проводилась.